

Sistemas de Múltiplos Modelos (Ensembles)

1. Como combinar as previsões dos diferentes modelos

Métodos de votação vs. métodos de serialização (fusão de classificadores)

Nos métodos de votação (voting), cada classificador dá um voto em uma classe e a decisão final sai por maioria ou pela média das probabilidades. É uma abordagem simples e que roda em paralelo. Já nos métodos de serialização os classificadores ficam encadeados em sequência, e a saída de um serve de entrada para o próximo, o que permite ir corrigindo os erros aos poucos.

Métodos estáticos vs. métodos dinâmicos

Nos métodos estáticos a forma de combinar os modelos é definida de antemão e não muda de acordo com o exemplo, então todos os modelos pesam igual para qualquer entrada. Nos métodos dinâmicos o peso ou a seleção de cada modelo é decidido na hora do teste, levando em conta as características do exemplo que está sendo classificado.

Os métodos dinâmicos levam em consideração o exemplo sendo classificado?

Sim. Métodos como Dynamic Classifier Selection (DCS) e Dynamic Ensemble Selection (DES) olham a vizinhança local do novo exemplo no espaço de atributos para descobrir quais modelos vão melhor naquela região, e a partir disso dão mais peso a eles ou selecionam apenas os de melhor desempenho local.

2. Métodos de seleção dinâmica

MAI - Model Applicability Induction

O MAI tenta estimar o quanto cada modelo base se aplica a uma nova instância. Para isso treina um meta-modelo que prevê quando um classificador costuma acertar ou errar, e usa essa informação para guiar a seleção dinâmica. No fundo é uma seleção dinâmica baseada na indução de regiões de competência.

SCANN - Análise de Correspondência Seguida por um Vizinho Mais Próximo

O SCANN usa análise de correspondência para projetar o espaço de entrada numa dimensão menor que mantém as relações de semelhança entre instâncias e modelos. Depois aplica um classificador de vizinho mais próximo nesse espaço projetado para escolher dinamicamente o modelo mais adequado.

3. Bootstrap, Bagging, Boosting e AdaBoost

Bootstrap

O Bootstrap é a técnica de reamostragem com reposição que está na base dos outros métodos. A partir de um conjunto com N exemplos, monta-se um novo conjunto de treino também com N exemplos, sorteando aleatoriamente e permitindo repetição, o que acaba deixando cerca de 63% de exemplos únicos.

Com isso dá para simular várias amostras a partir de um único conjunto, estimar a variabilidade e reduzir o overfitting.

Bagging

O Bagging (Bootstrap Aggregating) usa o Bootstrap para gerar vários subconjuntos e treina um modelo diferente em cada um, tudo de forma paralela e independente. No fim, a predição sai por maioria de votos na classificação ou por média na regressão. Isso reduz a variância sem adicionar viés, e funciona especialmente bem com modelos instáveis como as árvores de decisão.

Boosting

O Boosting faz o contrário do Bagging. Aqui os modelos são treinados em sequência, e cada modelo novo foca justamente nos exemplos que os anteriores erraram, aumentando o peso desses casos a cada rodada. A ideia é ir reduzindo o viés e juntar vários modelos fracos em um conjunto forte.

AdaBoost

O AdaBoost (Adaptive Boosting) é a versão mais conhecida do Boosting. Cada exemplo tem um peso que aumenta sempre que ele é classificado errado. A cada rodada um classificador fraco (em geral um decision stump) é treinado com os pesos do momento e recebe um coeficiente de confiança α conforme a sua acurácia. A predição final é uma soma ponderada por esses α , então os classificadores melhores acabam tendo mais influência.

4. Random Forest

O Random Forest junta o Bagging a uma segunda dose de aleatoriedade. Além de treinar cada árvore num bootstrap dos dados, em cada nó ele só considera um subconjunto aleatório de k atributos (normalmente $\sqrt{p}$ na classificação) para escolher a divisão. Esse mecanismo duplo descorrelaciona as árvores: se um atributo dominante estivesse sempre disponível, as árvores ficariam todas parecidas. Como resultado, o conjunto fica mais diverso e robusto, com baixa variância, boa resistência a outliers e ruído, bom desempenho em dados de alta dimensionalidade, e ainda fornece de brinde uma medida de importância das variáveis.

5. Stacking

O Stacking (ou Stacked Generalization) é um método de ensemble em dois níveis que vai além da votação simples: em vez de combinar os modelos por uma regra fixa, ele aprende a melhor forma de combiná-los. No nível 0, vários modelos diferentes entre si, por exemplo uma árvore de decisão, um SVM e um KNN, são treinados sobre o mesmo conjunto de dados, com algoritmos e hiperparâmetros distintos para garantir diversidade. As predições desses modelos viram as meta-features, ou seja, novas colunas de entrada para um segundo modelo.

No nível 1 entra o meta-learner, normalmente um modelo simples como uma regressão logística ou linear, que é treinado sobre essas meta-features e aprende a combinar as saídas dos modelos do nível 0. O cuidado mais importante aqui é

evitar o data leakage: se as meta-features viessem do mesmo conjunto usado para treinar os modelos base, o meta-learner estaria aprendendo com previsões boas demais, infladas. Para resolver isso usa-se validação cruzada com out-of-fold predictions, em que cada modelo base só prevê nos folds em que não foi treinado, gerando meta-features sem esse viés.

Dá para estender o Stacking para mais níveis (deep stacking), empilhando camadas de meta-learners, embora na prática dois níveis já costumem trazer quase todo o ganho. É um dos métodos de ensemble com melhor desempenho em benchmarks e competições, justamente porque aprende a aproveitar o que cada modelo tem de diferente.