

Disciplina de Inteligência Artificial

Professor Munif | Unicesumar 2026

Trabalho Final

Comparação de Modelos de IA: KNN vs Random Forest

Classificação de Tipos de Treino Físico

HIIT | Hipertrofia | Treino Concorrente

Dataset: HIIT vs Hypertrophy Workout Gains — Kaggle

Modelos: K-Nearest Neighbors e Random Forest

Método de Avaliação: Holdout (70% treino / 30% teste)

1. Tema do Projeto

Comparação de Modelos de Inteligência Artificial para Classificação de Tipos de Treino Físico com base em Variáveis Fisiológicas e de Desempenho.

O projeto utiliza técnicas de aprendizado de máquina supervisionado para investigar se é possível identificar automaticamente qual tipo de treino um participante realizou — HIIT, Hipertrofia ou Treino Concorrente — com base em seus dados fisiológicos e de desempenho.

2. Problema Investigado

Dado um conjunto de variáveis fisiológicas e de desempenho físico de praticantes de exercício, modelos de aprendizado de máquina são capazes de classificar corretamente o tipo de protocolo de treino realizado?

Esse problema é relevante porque a correta identificação do tipo de treino por meio de dados pode contribuir para a prescrição automatizada de exercícios, monitoramento de atletas e personalização de programas de saúde.

3. Hipótese

Modelos de aprendizado de máquina supervisionado são capazes de classificar o tipo de treino realizado (HIIT, Hipertrofia ou Concorrente) com base em variáveis fisiológicas, sendo o Random Forest superior ao KNN devido à sua capacidade de lidar com dados heterogêneos, capturar interações não lineares entre variáveis e ser mais robusto a outliers.

4. Dataset

Atributo	Detalhe
Nome	HIIT vs Hypertrophy Workout Gains Dataset
Origem	Kaggle — sohaibdevv
Formato	CSV
Registros	200 participantes
Colunas	12
Valores nulos	Nenhum (dataset limpo)

4.1 Colunas do Dataset

Coluna	Tipo	Descrição
Participant_ID	String	Identificador único (removido no pré-processamento)
Age	Inteiro	Idade do participante
Gender	Categórico	Gênero (codificado numericamente)
Group	Categórico	VARIÁVEL ALVO — tipo de treino
Duration_Weeks	Inteiro	Duração do programa em semanas

Compliance_Rate	Float	Taxa de adesão ao programa
Initial_Body_Fat_Pct	Float	Percentual de gordura inicial
Final_Body_Fat_Pct	Float	Percentual de gordura final
Initial_Lean_Mass_kg	Float	Massa magra inicial (kg)
Final_Lean_Mass_kg	Float	Massa magra final (kg)
VO2_Max_Change_Pct	Float	Variação percentual do VO2 máximo
Dietary_Condition	Categórico	Condição alimentar (Surplus/Deficit)

5. Variável Alvo

A variável alvo é **Group**, que representa o tipo de protocolo de treino. Possui três classes, tornando o problema de classificação multiclasse:

Classe	Significado	Registros
HIIT_Only	Apenas treino intervalado de alta intensidade	61
Hypertrophy_Only	Apenas treino de hipertrofia	76
Concurrent	Combinação de HIIT e hipertrofia	63

6. Tipo de Problema

Classificação Multiclasse Supervisionada. Os dados possuem rótulos definidos (três categorias de treino) e o objetivo é aprender um mapeamento entre as features fisiológicas e o tipo de treino realizado.

7. Metodologia — Holdout

O método **Holdout** foi aplicado para separar os dados em conjuntos de treino e teste, garantindo que o modelo seja avaliado em dados que nunca foram vistos durante o treinamento.

Conjunto	Proporção	Registros
Treino	70%	140
Teste	30%	60

8. Pré-processamento

8.1 Verificação de Nulos: O dataset não apresentou nenhum valor nulo. Nenhum tratamento de imputação foi necessário.

8.2 Remoção de Coluna Irrelevante: A coluna Participant_ID foi removida por ser um identificador único sem valor preditivo.

8.3 Codificação Categórica: Gender e Dietary_Condition foram codificados com LabelEncoder. A variável alvo Group também foi codificada.

8.4 Normalização: Todas as features numéricas foram normalizadas com StandardScaler (média 0, desvio padrão 1), essencial para o KNN.

9. KNN — K-Nearest Neighbors

O KNN é um algoritmo baseado em instâncias que classifica um novo ponto calculando sua distância para os K vizinhos mais próximos no conjunto de treino e atribuindo a classe majoritária entre esses vizinhos.

Parâmetros utilizados: `n_neighbors=5`, métrica de distância Euclidiana.

10. Random Forest — Floresta Aleatória

O Random Forest é um ensemble de árvores de decisão treinadas com subconjuntos aleatórios dos dados e das features. A predição final é determinada por votação majoritária entre todas as árvores.


Parâmetros utilizados: `n_estimators=100`, `random_state=42`.

11. Resultados e Métricas



11.1 Tabela Comparativa

Métrica	KNN	Random Forest
Acurácia	65,00%	88,33% ✓
Precisão (weighted)	69,62%	88,24% ✓
Recall (weighted)	65,00%	88,33% ✓
F1-Score (weighted)	66,21%	88,02% ✓

11.2 Gráficos




Matriz de Confusão — KNN




Comparação de Acurácia

Comparação de Acurácia — KNN vs Random Forest




Comparação de F1-Score

Comparação de F1-score — KNN vs Random Forest



Comparação Completa de Métricas



12. Comparação dos Modelos

O Random Forest superou o KNN em todas as métricas avaliadas, com uma diferença de **23,33 pontos percentuais** na acurácia. A classe Concurrent foi a mais difícil de classificar para ambos os modelos, o que faz sentido: o treino concorrente combina características de HIIT e hipertrofia, tornando os padrões fisiológicos menos distintos.

Aspecto	KNN	Random Forest
Acurácia	65,00%	88,33% ✓
Melhor classe	Hypertrophy (F1=0.75)	Hypertrophy (F1=0.96) ✓
Pior classe	Concurrent (F1=0.53)	Concurrent (F1=0.80) ✓
Sensibilidade à escala	Alta	Baixa ✓
Interpretabilidade	Média	Baixa
Tempo de treino	Muito rápido	Moderado

13. Conclusão Crítica

Modelo Vencedor: Random Forest (88,33% de acurácia)

O Random Forest obteve desempenho claramente superior ao KNN em todas as métricas. Essa diferença significativa pode ser explicada pela capacidade do ensemble de 100 árvores em capturar padrões não lineares que o KNN, baseado apenas em distância euclidiana, não consegue representar. Com apenas 200 registros, o RF consegue generalizar melhor por meio do bagging.

Vantagens e Limitações do KNN:

Vantagens: simples de entender e implementar, não faz suposições sobre a distribuição dos dados, bom desempenho em datasets pequenos e bem separados. Limitações: sensível à escala das variáveis, desempenho degrada em alta dimensionalidade, lento em produção para datasets grandes, sensível a dados ruidosos e outliers.

Vantagens e Limitações do Random Forest:

Vantagens: alta acurácia mesmo com dados heterogêneos, robusto a outliers e ruídos, fornece importância das features. Limitações: menos interpretável (caixa preta), maior consumo de memória, pode sofrer overfitting em datasets muito pequenos com muitas árvores.

Limitações do Dataset:

Apenas 200 registros é um volume reduzido. Todas as observações têm a mesma duração (12 semanas), limitando a variabilidade temporal. A variável Duration_Weeks tem variância zero, não contribuindo para o aprendizado. O dataset pode ser sintético, o que reduz a aplicabilidade em cenários reais.

Possíveis Melhorias Futuras:

Utilizar validação cruzada (K-Fold) para avaliação mais robusta; aplicar otimização de hiperparâmetros com GridSearchCV; testar modelos como SVM, Gradient Boosting ou Redes Neurais; ampliar o dataset com mais participantes e variabilidade temporal; avaliar a importância das features no Random Forest.

Referências

- BREIMAN, L. Random Forests. Machine Learning, v. 45, n. 1, p. 5-32, 2001.
- COVER, T.; HART, P. Nearest neighbor pattern classification. IEEE Transactions on Information Theory, v. 13, n. 1, p. 21-27, 1967.
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.
- Dataset: HIIT vs Hypertrophy Workout Gains Dataset - Kaggle (sohaibdevv).